

课程报告一：手搓多层神经网络

方俊睿

学号：3230104069

1 问题 1：反向传播算法的计算图表示

我对反向传播的理解是：先把网络前向计算拆成一个个小步骤（也就是计算图里的节点和边），然后再按相反方向把梯度传回来。这样做的好处是每一步都很清楚，哪里算错、哪里梯度变小，都比较容易定位。对多层感知机来说，每层都可以写成

$$a^{(l-1)} \rightarrow z^{(l)} \rightarrow a^{(l)} \rightarrow \mathcal{L}$$

也就是“线性变换 $\rightarrow$ 激活函数 $\rightarrow$ 损失函数”这条链路。




图 1：反向传播计算图示意

以前馈网络第 l 层为例，前向计算是：

$$z^{(l)} = W^{(l)} a^{(l-1)} + b^{(l)}, \quad a^{(l)} = f(z^{(l)})$$

其中 $a^{(0)} = x$ ，输出层 $a^{(L)} = \hat{y}$ 。如果第 l 层有 $m^{(l)}$ 个神经元，那么

$$W^{(l)} \in \mathbb{R}^{m^{(l)} \times m^{(l-1)}}, \quad b^{(l)} \in \mathbb{R}^{m^{(l)}}, \quad a^{(l)} \in \mathbb{R}^{m^{(l)}}$$

这个维度关系保证了各层矩阵乘法能对上。

反向传播本质上就是链式法则：

$$\text{标量: } \frac{dz}{dx} = \frac{dz}{dg} \frac{dg}{dx}, \quad \text{向量: } \frac{\partial z}{\partial \mathbf{x}} = \frac{\partial \mathbf{y}}{\partial \mathbf{x}} \frac{\partial z}{\partial \mathbf{y}}$$

放到计算图里看，就是每个节点先接收“上游梯度”，再乘当前节点的“局部导数”。

若损失函数为 $\mathcal{L}$ ，定义误差项

$$\delta^{(l)} = \frac{\partial \mathcal{L}}{\partial z^{(l)}}$$

则输出层和隐藏层的反向递推分别为：

$$\delta^{(L)} = \frac{\partial \mathcal{L}}{\partial a^{(L)}} \odot f'(z^{(L)})$$

$$\delta^{(l)} = \left(W^{(l+1)}\right)^T \delta^{(l+1)} \odot f'(z^{(l)})$$

其中 $\odot$ 为逐元素乘法。

常见激活函数的局部导数：

$$\sigma'(x) = \sigma(x)(1 - \sigma(x)), \quad \tanh'(x) = 1 - \tanh^2(x)$$

$$\text{ReLU}'(x) = \begin{cases} 1, & x > 0 \\ 0, & x \leq 0 \end{cases}$$

这些导数的大小直接影响梯度会不会变得太小，从而影响训练速度和稳定性。

因此各层参数梯度可统一写为：

$$\frac{\partial \mathcal{L}}{\partial W^{(l)}} = \delta^{(l)} \left(a^{(l-1)}\right)^T, \quad \frac{\partial \mathcal{L}}{\partial b^{(l)}} = \delta^{(l)}$$

最后用梯度下降类方法更新参数。整体流程可以概括为：先前向算输出，再算输出层误差，接着逐层反传，最后更新参数。

2 问题 2：基于多层感知机的 FashionMNIST 图像分类实验

2.1 问题简介

这一部分我主要做了一件事：用课程给的 `demo_mnist_ann.py` 自己把 MLP 在 FashionMNIST 上跑通，再看看不同配置到底差在哪。相比只看最终准确率，我更关心的是训练过程本身，比如有没有稳定上升、会不会卡住、不同参数改完后曲线变化大不大。

实验里重点比较了三类因素：激活函数（Sigmoid、Tanh、ReLU、ReLU3）、优化算法（GD、SGD、ADAM）和学习率。评价标准也比较直接：训练集准确率、测试集准确率，以及训练曲线的变化趋势。最后目标是给出一个在当前代码和机器条件下更稳、更好用的组合。

2.2 模型与算法介绍

模型用的是最基础的前馈全连接网络。按当前代码，网络结构是

$$784 \rightarrow 128 \rightarrow 64 \rightarrow 10$$

输入 784 是把 28×28 的图像拉平成向量，输出 10 对应 10 个类别。中间两层隐藏层分别是 128 和 64 个神经元。激活函数支持 Sigmoid、Tanh、ReLU、ReLU3；优化器支持 GD、SGD、ADAM。代码层面还做了 CPU/GPU 双后端，能在 NumPy 和 CuPy 之间切换。

核心计算还是标准的前向 + 反向：

$$z^{(l)} = W^{(l)} a^{(l-1)} + b^{(l)}, \quad a^{(l)} = f(z^{(l)})$$

$$\delta^{(l)} = \left(W^{(l+1)}\right)^T \delta^{(l+1)} \odot f'(z^{(l)})$$

$$\frac{\partial \mathcal{L}}{\partial W^{(l)}} = \delta^{(l)} \left(a^{(l-1)}\right)^T$$

当前实现里损失函数用的是误差平方和（SSE），每个 epoch 按选定优化器更新参数。需要注意的是，当前实验采用的是误差平方和（SSE）损失，而分类任务中更常见的是交叉熵损失。SSE 在 Sigmoid 输出场景下可能出现梯度偏小的问题，从而影响收敛速度，这也是后续结果分析时需要考虑的因素之一。

三种优化算法可以简单理解为：

$$\text{GD} : \theta \leftarrow \theta - \eta \cdot \frac{1}{N} \sum_{i=1}^N \nabla_{\theta} \mathcal{L}_i$$

$$\text{SGD} : \theta \leftarrow \theta - \eta \cdot \nabla_{\theta} \mathcal{L}_{i_t}$$

$$\text{ADAM} : \begin{cases} m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t \\ v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2 \\ \theta_t = \theta_{t-1} - \eta \frac{\hat{m}_t}{\sqrt{\hat{v}_t + \epsilon}} \end{cases}$$

直观上，GD 用全样本平均梯度，SGD 用单样本近似梯度，ADAM 在梯度基础上再做一阶/二阶动量修正，通常调好学习率后更容易得到稳定结果。

表 1: 模型与训练算法配置

项目	配置
网络结构	784 $\rightarrow$ 128 $\rightarrow$ 64 $\rightarrow$ 10
激活函数	Sigmoid / Tanh / ReLU / ReLU3
优化算法	GD / SGD / ADAM
损失形式	误差平方和（代码实现）
计算后端	NumPy (CPU) / CuPy (GPU)

2.3 数据集和算例参数介绍

FashionMNIST 数据集包含 60000 张训练图像和 10000 张测试图像，单张图像大小为 28×28 。为控制计算开销，算例中按不同实验设置抽取部分样本训练与测试。

表 2: 数据集与算例参数

项目	数值
完整训练集大小	60000
完整测试集大小	10000
图像尺寸	28×28
分类类别数	10
典型训练轮次	10000

2.4 结果罗列与汇总

(1) 不同激活函数 + SGD（学习率 0.1）

表 3: 不同激活函数在 SGD 下的结果

训练轮次	激活函数	学习率	训练样本数	测试样本数	训练集准确率	测试集准确率
10000	Sigmoid	0.1	5000	1000	0.8436	0.812
10000	Tanh	0.1	5000	1000	0.6128	0.535
10000	ReLU	0.1	5000	1000	0.0914	0.107
10000	ReLU3	0.1	5000	1000	0.0914	0.107




图 2: 不同激活函数在 SGD 下的训练过程

(2) Sigmoid + GD

表 4: Sigmoid + GD 结果

训练轮次	学习率	训练样本数	测试样本数	训练集准确率	测试集准确率
10000	0.1	500	100	0.956	0.79




图 3: Sigmoid + GD 训练曲线

(3) Sigmoid + ADAM (学习率对比)

表 5: Sigmoid + ADAM 在不同学习率下的结果

训练轮次	学习率	训练样本数	测试样本数	训练集准确率	测试集准确率
10000	0.1	5000	1000	0.1112	0.105
10000	0.01	5000	1000	0.9896	0.835
10000	0.001	5000	1000	0.9178	0.839




图 4: ADAM 对比实验过程图

表 6: 主要结果汇总

实验组合	关键参数	测试准确率	结论
Sigmoid + SGD	lr=0.1	0.812	收敛稳定, 表现较好
Tanh + SGD	lr=0.1	0.535	训练波动较大
ReLU/ReLU3 + SGD	lr=0.1	0.107	近似随机猜测
Sigmoid + GD	小样本 (500/100)	0.790	存在过拟合倾向
Sigmoid + ADAM	lr=0.001-0.01	0.839	综合最优

2.5 结果分析

从这组实验结果看, 激活函数和优化器的搭配确实会直接影响模型效果。在同样使用 SGD、学习率都设为 0.1 的情况下, Sigmoid 可以做到 0.812, Tanh 只有 0.535, 而 ReLU/ReLU3 基本停在 0.1 左右, 几乎就是随机猜。这个结果说明在我当前这套初始化和参数设置下, ReLU 系列没有被很好地训练起来。这一现象可能和当前实验设置有关: 一方面, 学习率 0.1 对 ReLU 来说可能偏大, 早期更新不稳定; 另一方面, 若初始化方

式与 ReLU 不匹配 (如未使用 He 初始化), 也可能使部分神经元较早进入“死亡 ReLU”状态, 导致梯度传播受阻。

另外一个比较明显的现象是: Sigmoid + GD 的训练集准确率很高 (0.956), 但测试集只有 0.790。结合这组实验的样本量 (500/100) 来看, 过拟合是比较合理的解释。ADAM 的对比也很典型: 学习率 0.1 时几乎没法训练 (0.105), 降到 0.01 和 0.001 后马上提升到 0.835/0.839。也就是说, ADAM 不是“天然就好用”, 学习率选得不合适一样会失败。

2.6 结论

1. 用手写 MLP 做 FashionMNIST 是可行的, 参数设置合理时测试准确率可以稳定在 0.8 以上。
2. 这次实验里 Sigmoid 的表现最稳, Tanh 次之, ReLU/ReLU3 在当前设置下效果不理想。
3. 学习率非常关键, 尤其在 ADAM 上体现得很明显; 0.1 基本不可用, 0.01 和 0.001 效果明显更好。
4. 如果按这份实验结果选一个默认方案, 我会优先用 **Sigmoid + ADAM (学习率 0.001~0.01)**。

2.7 程序性能改进尝试

- **从只跑 CPU 到支持 GPU:** 最初版本全部是 NumPy, 当前版本加了 CuPy 和 `use_gpu`, 有 GPU 时训练速度会快很多。
- **统一计算接口:** 用 `xp` 把 NumPy/CuPy 统一起来, 前向、反向和评估都走同一套逻辑, 代码更好维护, 也少了很多重复判断。
- **数值与数据处理更稳:** 输入改成 `float32` 并做了归一化 (除以 255), 内存占用更小, 训练过程也更稳定。
- **设备转换更顺手:** 增加了 `to_gpu`、`to_cpu`、`get_xp` 这些函数, 减少了手工搬运数据时容易犯错的地方。
- **训练过程更可观察:** 现在会记录 `precision_history/perf_history`, 还能直接画曲线, 这对调参很有帮助, 不用只看最后一个准确率。

3 代码附录

以下代码片段来自 `demo_mnist_ann.py`, 用于说明关键实现逻辑。

1. 网络初始化与优化器选择

```

class NeuralNetwork:
    def __init__(self, layers, activation, opt_alg,
                 use_gpu=True):
        self.use_gpu = use_gpu and GPU_AVAILABLE
        self.xp = cp if self.use_gpu else np

        if activation == 'sigmoid':
            self.activation = sigmoid
            self.activation_deriv = sigmoid_deriv
        elif activation == 'tanh':
            self.activation = tanh
            self.activation_deriv = tanh_deriv

        if opt_alg == 'GD':
            self.opt = self.GD
        elif opt_alg == 'SGD':
            self.opt = self.SGD
        elif opt_alg == 'ADAM':
            self.opt = self.ADAM

```

2. 反向传播梯度计算

```

xp = self.xp
for i in range(n_w-1, -1, -1):
    if i == n_w-1:
        delta[i] = error * self.activation_deriv(z[i])
    else:
        delta[i] = xp.dot(self.weights[i+1].T, delta[i+1]) * \
            self.activation_deriv(z[i])

for i in range(n_w):
    dweights.append(xp.dot(delta[i], K[i].T))
    dthetas.append(delta[i])

```

3. 训练与测试流程

```

layers = np.array([X.shape[0], 128, 64, Y.shape[0]])
Net = NeuralNetwork(layers, 'sigmoid', 'GD', use_gpu=True)
Net.train(X, Y, 1, 0.1, 10000)
Net.plot_precision("figures/sigmoid_GD.png")

testX_dev = to_gpu(testX) if GPU_AVAILABLE else testX
testY_dev = to_gpu(testY) if GPU_AVAILABLE else testY
output = Net.propagation(testX_dev, 1)
xp = cp if GPU_AVAILABLE else np
true = int(to_cpu(xp.sum(xp.argmax(testY_dev, axis=0)
    == xp.argmax(output, axis=0))))
print("test precision:", true / testX.shape[1])

```