

课程报告二：从头训练 V.S. 微调 (ResNeXt 与 DenseNet)

方俊睿

学号：3230104069

仓库地址：<https://github.com/Tomabsolute/Neul.git>

1 实验背景介绍

在视觉分类任务中，模型训练通常有两条路线：一是从随机初始化开始训练 (from scratch)，二是基于大规模数据集预训练权重进行迁移学习 (fine-tune)。前者理论上更灵活，但通常需要更大的数据量和更长训练时间；后者利用已有通用特征表示，往往能在中小规模任务上更快收敛并获得更好的泛化性能。

本课程任务要求围绕“从头训练 V.S. 微调”进行实证比较，核心问题包括：预训练是否稳定带来收益、收益主要体现在精度还是训练成本、不同网络结构对迁移学习的响应是否一致。为回答这些问题，本实验选择 ResNeXt50_32x4d 与 DenseNet121 两种代表性骨干网络，在同一数据集、同一训练框架下进行四组对照实验，尽量保证比较公平。

从应用角度看，这一问题也具有工程意义：在实际项目中，算力预算和迭代周期通常受限，是否优先采用微调策略会直接影响开发效率；而在数据规模逐步扩大后，从头训练是否仍有必要，也需要通过定量结果来判断。因此，本实验不仅报告最终指标，还重点分析收敛速度、泛化差距与训练时长之间的权衡关系。

2 实验任务与目标

本实验按照课程要求，对比两种模型 (ResNeXt50_32x4d、DenseNet121) 在同一多分类任务上的两类训练方式：

- 从头训练 (from scratch)
- 微调 (fine-tune)

核心关注点包括：收敛速度、最终精度 (Top-1 Accuracy)、泛化能力 (Macro-F1) 以及训练时间成本。

3 数据集与预处理

3.1 数据集介绍

实验使用 Food101 数据集 (101 类)。数据划分与规模为：

- 训练集原始大小：75750
- 在训练集中再划分：train=68175, val=7575 (val_ratio=0.1)
- 测试集大小：25250

3.2 预处理与增强

输入尺寸统一为 224×224 ，预处理为：

- 训练集：RandomResizedCrop(224) + RandomHorizontalFlip + ImageNet Normalize
- 验证/测试集：Resize(256) + CenterCrop(224) + ImageNet Normalize

4 模型与训练策略

4.1 统一训练配置

表 1: 统一配置

项目	配置
损失函数	CrossEntropyLoss
优化器	SGD (momentum=0.9, weight_decay= 1×10^{-4})
指标	Top-1 Accuracy, Macro-F1
硬件	CUDA, 2 GPU, DataParallel, AMP
Batch size	64

4.2 四组实验

1. ResNeXt50_32x4d - scratch
2. ResNeXt50_32x4d - finetune

3. DenseNet121 - scratch

4. DenseNet121 - finetune

微调采用两阶段策略：第一阶段冻结 backbone 仅训练分类头 (10 epoch)；第二阶段解冻全网，backbone 与 head 使用不同学习率 (backbone: 1e-4, head: 1e-3)。

5 实验结果汇总

表 2: 四组实验结果总表

实验	best val acc	test acc	test macro-F1	train(s)	train(h)
ResNeXt-scratch	0.728317	0.785743	0.785183	11921.7	3.3116
ResNeXt-finetune	0.753267	0.797782	0.795660	9466.3	2.6295
DenseNet-scratch	0.737294	0.793703	0.793251	24265.5	6.7404
DenseNet-finetune	0.775710	0.823960	0.823020	19733.8	5.4816

四组累计训练总时长为 **18.163 小时**，满足“训练时间不少于 2 小时”的课程要求。




图 1: 四组实验 Accuracy / Macro-F1 对比




图 2: 四组实验训练时长对比




图 3: ResNeXt50_32x4d: scratch vs finetune




图 4: DenseNet121: scratch vs finetune

6 结果分析

6.1 微调相对从头训练的收益

两种模型均表现出“微调优于从头训练”的一致结论：

- ResNeXt: test acc 从 0.7857 提升到 0.7978 (+1.20 个百分点), Macro-F1 +1.05 个百分点。
- DenseNet: test acc 从 0.7937 提升到 0.8240 (+3.03 个百分点), Macro-F1 +2.98 个百分点。

这说明在 Food101 任务上，迁移预训练特征可明显提升最终性能。

6.2 训练成本对比

微调不仅精度更高，时间开销也更低：

- ResNeXt: 3.3116h → 2.6295h (约减少 20.6%)
- DenseNet: 6.7404h → 5.4816h (约减少 18.7%)

原因主要是微调初始点更优，且冻结阶段减少了反向传播计算量。

6.3 收敛速度量化分析

为了避免只看最终精度，本报告进一步从训练过程做量化比较。这里定义“接近收敛轮次”为验证准确率首次达到“该实验最佳验证准确率的 95%”时的 epoch，统计结果如下。

表 3: 收敛速度与最佳轮次对比 (来自 history.csv)

实验	总 epoch	达到 95% 最佳值 epoch	最佳 val acc 轮次	末轮 train-val gap
ResNeXt-scratch	60	32	59	+0.1400
ResNeXt-finetune	50	23	47	-0.0488
DenseNet-scratch	60	33	56	+0.0942
DenseNet-finetune	50	21	50	-0.0406

从表中可见，微调在两种模型上都更早进入高精度区间 (比 scratch 早约 9-12 个 epoch)。同时，scratch

的末轮 train-val gap 为正且较大（尤其 ResNeXt 为 +0.14），体现出更明显的过拟合倾向；而 finetune 的末轮 gap 为负值，说明在较强数据增强和预训练初始化下，训练与验证之间的性能差距更小，整体泛化更稳。

6.4 微调两阶段的效果拆解

微调不是单一策略，而是“冻结分类头训练 + 解冻全网联合训练”两阶段组合。以验证准确率为为例：

- ResNeXt-finetune：第 10 轮（冻结结束）val acc=0.4685，第 11 轮解冻后快速升至 0.5377。
- DenseNet-finetune：第 10 轮 val acc=0.5626，第 11 轮升至 0.6321。

这一“解冻后跃迁”说明：第一阶段主要完成分类头对新任务的适配；第二阶段通过低学习率微调 backbone，把通用视觉特征进一步向 Food101 的类别边界对齐。该策略在保持训练稳定性的同时，避免了“全网大步长更新”导致的预训练特征破坏。

6.5 ResNeXt 与 DenseNet 差异

在本次实验设置下，DenseNet121 整体优于 ResNeXt50_32x4d，且在 finetune 下优势最明显（test acc=0.82396，macro-F1=0.82302）。结合曲线和指标，可能原因包括：

- DenseNet 的密集连接带来更强特征复用，对多类别细粒度区分更有利。
- 在相同 batch size 与优化器参数下，DenseNet 的验证曲线波动更小，后期提升更连续。
- ResNeXt-scratch 的过拟合更重（末轮 gap 最大），说明其在当前训练预算下对正则化和调参更敏感。

6.6 单组训练曲线补充

为了更完整展示训练动态，附上四组实验各自的 loss/acc 曲线（每张图包含 train/val 两条线）。




图 5: ResNeXt50_32x4d-scratch 的训练曲线




图 6: ResNeXt50_32x4d-finetune 的训练曲线




图 7: DenseNet121-scratch 的训练曲线




图 8: DenseNet121-finetune 的训练曲线

7 实验不足与改进方向

7.1 当前实验的局限性

- 只使用了单次随机种子（seed=42），尚未报告均值与方差，统计稳定性不足。
- 超参数网格较小（尤其 scratch 的学习率与正则项），可能未充分发挥从头训练上限。
- 只评估了 Top-1 和 Macro-F1，尚未补充混淆矩阵、类别级错误分布等分析。
- 数据增强策略相对基础，未测试 MixUp、CutMix、RandAugment 等更强增强。

7.2 后续可执行改进

1. 进行 3-5 个随机种子重复实验，报告 mean±std，提高结论可靠性。
2. 对 scratch 单独做学习率与权重衰减搜索，缩小与 finetune 的性能差距。

3. 增加 warmup + cosine schedule 对比，观察收敛速度与最终精度变化。
4. 输出每类准确率与混淆矩阵，定位易混类别并针对性优化数据增强。

8 结论

1. 在本实验中，微调策略在两种模型上都带来稳定性能提升。
2. 微调兼顾了更高精度与更短训练时长，是该任务下更优先的训练方案。
3. 四组实验最优组合为 DenseNet121-finetune。