

课程报告三：基于条件 GAN 的小样本服饰图像生成

方俊睿

学号：3230104069

仓库地址：<https://github.com/Tomabsolute/Neul.git>

1 实验背景介绍

生成对抗网络 (Generative Adversarial Network, GAN) 通过生成器与判别器的对抗训练学习数据分布。生成器从随机噪声中合成样本，判别器判断输入是真实样本还是生成样本；两者在交替优化中形成博弈，使生成器逐步产生更接近真实数据的图像。

普通 GAN 只能进行无条件生成，无法直接控制输出类别。为了增强可控性，本实验选择条件 GAN (Conditional GAN, CGAN) 作为作业选题，将类别标签作为额外条件同时输入生成器和判别器，从而实现“指定类别生成图像”。与大规模人脸或复杂自然图像生成相比，Fashion-MNIST 尺寸小、类别清晰、训练成本低，更适合作为课程作业中的小样本 GAN 实验。

本实验参考了课程提供的 MNIST GAN 与 CGAN notebook，并整理为可复现的脚本工程，包含训练、推理、结果可视化与模型下载说明。

2 实验任务与目标

本实验目标是在小样本 Fashion-MNIST 上训练一个轻量级条件 DCGAN，实现以下功能：

- 使用类别标签控制生成结果，如指定生成 Trouser、Sneaker、Bag 等类别；
- 提供完整训练流程，可自动下载数据集并保存模型；
- 提供推理流程，可加载训练好的生成器并输出图像网格；
- 控制数据量与训练轮次，不追求高精度，只要求能观察到 GAN 从噪声到类别轮廓的学习过程。

3 数据集与预处理

3.1 数据集介绍

实验使用 Fashion-MNIST 数据集。该数据集包含 10 类灰度服饰图像，每张图像大小为 28×28 ，类别包括 T-shirt/top、Trouser、Pullover、Dress、Coat、Sandal、Shirt、Sneaker、Bag 与 Ankle boot。

为满足小样本训练要求，本实验没有使用完整训练集，而是从训练集中随机采样 20000 张图像。该设置比完整 Fashion-MNIST 更轻量，同时仍能保证每个类别有足够样本用于学习基本轮廓。

3.2 预处理

图像预处理较简单：

- 转为张量；
- 将像素从 $[0, 1]$ 归一化到 $[-1, 1]$ ；
- 生成器输出层使用 Tanh，与该归一化范围保持一致。

4 模型结构

4.1 生成器

生成器输入由两部分组成：随机噪声 z 与类别标签嵌入 $e(y)$ 。二者拼接后先经过全连接层映射到 $128 \times 7 \times 7$ 的特征图，再通过两层反卷积逐步上采样到 $1 \times 28 \times 28$ 。

表 1: 生成器结构

模块	输出尺寸
Noise + Label Embedding	$100 + 50$
Linear + BN + ReLU	$128 \times 7 \times 7$
ConvTranspose + BN + ReLU	$64 \times 14 \times 14$
ConvTranspose + Tanh	$1 \times 28 \times 28$

4.2 判别器

判别器同样接收类别标签。具体做法是将标签嵌入映射为 28×28 的条件图，再与真实或生成图像在通道维拼接，形成 $2 \times 28 \times 28$ 输入。随后通过两层卷积与全连接层输出真假 logit。

表 2: 判别器结构

模块	输出尺寸
Image + Label Map	$2 \times 28 \times 28$
Conv + LeakyReLU	$64 \times 14 \times 14$
Conv + BN + LeakyReLU	$128 \times 7 \times 7$
Flatten + Linear	1

5 训练策略

实验采用经典 GAN 交替训练方式。每个 batch 先更新判别器，再更新生成器。损失函数使用二元交叉熵的 logit 形式，因此判别器最后一层不额外接 Sigmoid。

$$\mathcal{L}_D = -\mathbb{E}_{x,y}[\log D(x,y)] - \mathbb{E}_{z,y}[\log(1 - D(G(z,y),y))], \quad (1)$$

$$\mathcal{L}_G = -\mathbb{E}_{z,y}[\log D(G(z,y),y)]. \quad (2)$$

表 3: 默认训练配置

项目	配置
数据集	Fashion-MNIST
训练样本数	20000
Epoch	50
Batch size	128
噪声维度	100
标签嵌入维度	50
优化器	Adam
学习率	2×10^{-4}
Adam β_1	0.5
设备	CUDA / MPS / CPU 自动选择

6 代码与运行方式

项目代码已随仓库提交，包含训练、推理、模型定义、曲线可视化和模型下载等部分。具体环境配置、一键训练命令、单独训练命令与推理命令均写在 README 文件中，复现实验时按 README 执行即可。

7 模型保存与下载

训练脚本会保存：

- 最终推理使用的生成器模型；
- 最后一轮完整模型；
- 每个 epoch 的损失与判别器分数记录；
- 训练过程中的固定噪声生成结果。

本次提交已经将训练好的模型放入 GitHub 仓库，因此克隆仓库并安装依赖后即可直接推理。若后续改为 Release 或网盘直链发布模型，下载方式也在 README 中说明。

8 实验结果记录方式

GAN 没有像分类任务一样直接的准确率指标，因此本实验主要记录以下训练信号：

- 判别器损失；
- 生成器损失；
- 判别器对真实样本的平均分数；
- 判别器对生成样本的平均分数；
- 固定噪声与固定标签下的生成图像变化。

理想情况下，训练初期生成图像接近随机噪声；训练若干轮后，不同标签对应的整体轮廓会逐渐分离，例如 Trouser 呈现竖直长条结构，Bag 更接近块状轮廓，Sneaker 与 Ankle boot 呈现鞋类横向轮廓。

表 4: 实际训练结果汇总

项目	数值
训练样本数	20000
训练轮数	50
最终 D loss	1.1678
最终 G loss	1.0780
最终 D(real)	0.5849
最终 D(fake)	0.4131
最后 10 轮平均 D loss	1.1674
最后 10 轮平均 G loss	1.0770




图 1: 条件 GAN 训练曲线



图 2: 最终模型按 0-9 类标签生成的 Fashion-MNIST 图像

9 结果分析

9.1 条件信息的作用

与无条件 GAN 相比, CGAN 在生成器和判别器两端都加入标签条件, 使模型学习 $p(x|y)$ 而非单一的 $p(x)$ 。生成器因此可以根据标签改变输出分布; 判别器也不只是判断图像真假, 还要判断图像与标签是否匹配。这种设置让推理阶段可以通过标签控制生成类别。

9.2 小样本训练的影响

本实验使用 20000 张图像, 约为完整训练集的三分之一。该设置保留了小样本实验的轻量特点, 同时生成结果已经能体现主要类别轮廓。形状差异较大的类别更容易辨认, 例如 Trouser、Sneaker、Bag、Ankle boot; 上衣类由于轮廓接近, 仍更容易发生类别混淆。

9.3 损失曲线解释

GAN 的损失不应像分类任务一样单调下降。若判别器过强, 对真实样本的分数接近 1 且对生成样本的分数接近 0, 生成器梯度可能变弱; 若判别器过弱, 生成器可能获得虚假的低损失。本次训练中, 后 10 轮判别器对真实样本的平均分数为 0.5848, 对生成样本的平均分数为 0.4144, 说明判别器仍能区分真实与生成样本, 但没有强到完全压制生成器。生成器损失在后期稳定在约 1.08, 生成图像也呈现较清晰的类别轮廓, 整体训练处于可接受的动态平衡状态。

9.4 可视化结果分析

从最终推理图可见, 模型已经学习到标签与整体形状之间的对应关系: 第 2 行 Trouser 具有明显的双腿纵向结构, 第 8 行 Sneaker 与第 10 行 Ankle boot 呈现鞋类横向轮廓, 第 9 行 Bag 呈块状结构。上衣相关类别之间仍存在混淆, 例如 T-shirt/top、Pullover、Coat 和 Shirt 的边界不够清晰, 这是 Fashion-MNIST 低分辨率与小型 DCGAN 容量共同造成的结果。

10 实验不足与改进方向

- 只使用低分辨率灰度图像, 生成结果主要体现轮廓, 视觉复杂度有限;
- 未引入 FID、IS 等生成质量指标, 评价主要依赖曲线与可视化;
- 小样本训练下可能出现模式坍塌, 可进一步加入谱归一化、标签平滑或 WGAN-GP;
- 如果希望生成更高质量图像, 可迁移到 CIFAR-10 或 CelebA, 并使用更深的 DCGAN / StyleGAN 结构。

11 结论

本实验完成了一个可复现的基于 GAN 的生成模型任务: 使用条件 DCGAN 在小样本 Fashion-MNIST 上进行类别可控图像生成。项目提供了训练脚本、推理脚本、可视化脚本与模型下载脚本, 满足“代码可获得、包含 train 脚本、模型可下载并运行推理”的课程提交要求。虽然默认训练配置不追求高精度和高画质, 但能够展示 GAN 对抗训练与条件生成的核心思想。